



Licenciatura em Engenharia Informática
Projeto de Engenharia Informática em Contexto Empresarial
3º ano

Fábio Miguel Domingues Monteiro

DESENVOLVIMENTO DE UM CHATBOT INTELIGENTE

**Relatório de projeto orientado pelo Professor Doutor Justino Lourenço e
apresentado ao Instituto Superior Politécnico Gaya**

07 de 2026

Dedicatória

Dedico este relatório aos meus pais, irmãos e namorada pelo apoio incondicional que sempre me deram durante o meu percurso académico, contribuindo também para o meu crescimento pessoal.

Agradecimentos

Começo por agradecer ao Prof. Dr. Sérgio Sargo e ao Prof. Dr. Justino Lourenço, coordenadores do Instituto Politécnico Gaya pela orientação dada durante o meu percurso académico.

Um agradecimento especial à WideSkills, Lda. pelo voto de confiança que me deram para desenvolver este projeto, no qual adquiri diversas competências profissionais.

Uma enorme gratidão à minha família pelo amor incondicional e motivação que me deram durante esta etapa importante da minha vida.

Resumo

O presente relatório descreve o desenvolvimento e a implementação de um sistema inteligente de automação e suporte à gestão de e-mail nos serviços administrativos do Instituto Superior Politécnico Gaya (ISPGAYA). O objetivo principal do projeto consiste em reduzir a carga de trabalho dos funcionários da secretaria, o que otimiza tempo de resposta e a precisão da informação fornecida aos estudantes e utilizadores.

A metodologia adotada para a concretização deste estudo baseou-se na integração de várias tecnologias. Inicialmente, foi desenvolvido um automatismo de web scraping, com o propósito de extrair e atualizar, de forma recursiva e integral, toda a documentação institucional disponível no repositório digital da instituição. Esta base de conhecimento, composta por diversos documentos em formato PDF, foi posteriormente processada e indexada no Azure AI Search, garantindo a sua disponibilidade para consultas em linguagem natural.

Para a lógica de resposta aos e-mails, foi implementado um sistema de Retrieval-Augmented Generation (RAG), que combina a capacidade analítica da OpenAI com os dados institucionais fidedignos. O fluxo de trabalho é despoletado através da plataforma Power Automate, que encaminha os e-mails recebidos para uma API desenvolvida em Python, responsável pela extração de palavras-chave, pesquisa semântica e geração de propostas de resposta adequadas ao contexto de cada solicitação.

Os resultados obtidos demonstram a eficácia da solução proposta, permitindo uma resposta rápida, precisa e coerente com as normas e regulamentos do ISPGAYA. O sistema revelou-se capaz de tratar eficazmente subpastas de níveis profundos e de filtrar informação redundante, demonstrando uma elevada resiliência perante novos dados. No final do documento, é apresentada uma reflexão crítica sobre o projeto, abordando as aprendizagens técnicas adquiridas na integração de serviços em nuvem, bem como as dificuldades superadas durante a fase de desenvolvimento e implementação da arquitetura.

Abstract

Lista de abreviaturas e siglas

ISPGAYA Instituto Superior Politécnico Gaya.

ESI Exploração de Sistemas de Informação.

DSI Desenvolvimento de Sistemas de Informação.

GSI Gestão de Sistemas de Informação.

PSI Planeamento de Sistemas de Informação.

SI Sistemas Informáticos.

TI Tecnologias de Informação.

TIC Tecnologias de Informação e Comunicação.

Índice

Refere-se à numeração das divisões do trabalho pela ordem em que são apresentadas, com a respetiva indicação da página em que começa essa parte do trabalho.

Dedicatória.....	iii
Agradecimentos	iv
Resumo.....	v
Abstract.....	vi
Lista de abreviaturas e siglas.....	vii
Introdução	10
Capítulos, secções, partes...:	11
Conclusões	14
Referências bibliográficas	15
Glossário	15
Apêndices/anexos.....	15

Índice de apêndice/anexo

Índice de figuras

Índice de tabelas

Introdução

O presente trabalho enquadra-se no relatório final da unidade curricular de Projeto de Engenharia Informática em Contexto Empresarial da licenciatura em Engenharia Informática do ISPGAYA. No contexto atual de transformação digital, a gestão eficiente da comunicação institucional constitui um desafio crítico para as organizações. A elevada afluência de solicitações recebidas pelos serviços de secretaria, frequentemente caracterizadas pela natureza repetitiva e pela necessidade de consulta de normativos complexos, justifica a implementação de soluções baseadas em Inteligência Artificial. O presente projeto surge, assim, como uma resposta à necessidade de otimizar a triagem e o processamento de informação administrativa, procurando colmatar a lacuna existente entre a disponibilidade de documentação pública e a agilidade necessária no atendimento ao estudante.

Através da realização do presente trabalho, pretendeu-se implementar um sistema de automação para a triagem e processamento de e-mails recebidos na secretaria, desenvolver uma base de conhecimento inteligente alimentada de forma automática a partir do repositório documental da instituição, e criar uma solução tecnológica que permita o suporte à decisão administrativa através da geração de propostas de resposta automáticas, mantendo sempre a validação humana. Adicionalmente, procurou-se garantir a resiliência e a fiabilidade do sistema perante falhas técnicas ou limitações de processamento. Todos os objetivos enunciados foram atingidos, resultando numa ferramenta funcional e integrada no fluxo de trabalho administrativo.

O projeto foi desenvolvido no âmbito das atividades de apoio à secretaria do ISPGAYA, que é uma instituição de ensino superior politécnico dedicada à formação técnica e científica em diversas áreas de gestão, engenharia e tecnologias, desempenhando um papel fundamental na região. A instituição caracteriza-se por um forte foco na inovação pedagógica e na modernização dos seus processos internos, áreas onde este projeto se insere estrategicamente.

A metodologia adotada pautou-se por uma abordagem de engenharia de software ágil, estruturada em três eixos principais: o desenvolvimento de mecanismos de web scraping recorrendo a técnicas de navegação dinâmica e análise de hipertexto, a implementação de um modelo de Retrieval-Augmented Generation para assegurar

respostas baseadas em factos institucionais, e a criação de uma API de comunicação robusta, capaz de integrar sistemas heterogéneos como servidores de e-mail e modelos de linguagem.

Este relatório encontra-se organizado de forma a refletir o ciclo de vida do desenvolvimento do sistema. Na primeira parte, é efetuado o enquadramento do projeto e a definição dos seus objetivos. Segue-se a descrição da arquitetura tecnológica, onde se detalham as ferramentas utilizadas e o fluxo de dados implementado. Posteriormente, explicita-se a metodologia de desenvolvimento, abordando os desafios técnicos superados, nomeadamente na extração recursiva de dados. Por fim, apresenta-se a discussão dos resultados obtidos, acompanhada pelas conclusões e por uma reflexão crítica sobre a aprendizagem consolidada ao longo de todo o projeto.

Capítulos, secções, partes...:

- Engloba o desenvolvimento sequencial dos temas, onde se desenvolve a descrição, análise, sistematização e explicação da temática.
- Pode ser subdividido em partes, capítulos, subcapítulos, de acordo com as exigências do tema e as opções do autor.
- Deve conter, entre outros, capítulos, secções, partes:
 - » **Caracterização da entidade de estágio**
 - Caso se aplique, descrever a entidade de estágio e o departamento onde executou as atividades.
 - » **Projeto similares e associados**
 - Apresentação e descrição da solução tecnológica existente na empresa (caso seja um projeto de melhoria de uma solução previamente instalada empresa).
 - Análise de projetos similares disponíveis no mercado ou desenvolvidos por outras empresas/instituições.
 - » **Bases teóricas**
 - Revisão da literatura que suporta a execução do trabalho, procedendo-se a uma melhoria deste capítulo já presente no relatório introdutório.
 - » **Requisitos**
 - Definição dos requisitos técnicos (funcionais e não-funcionais).
 - Detalhar cada um dos requisitos com recurso, por exemplo, no caso de Eng.^a Informática, à linguagem de modelação UML. Devem ser usados diagramas

de casos de utilização, diagramas de sequência, diagramas de estados e diagramas de componentes.

- Análise e descrição da arquitetura do sistema.

» **Descrição do trabalho/atividades realizadas**

- Descrição exaustiva do trabalho e atividades efetuadas, apresentando os resultados.

» **Testes de validação**

Exemplo:

- Apresentação e descrição dos casos de teste de validação do sistema, usando uma tabela idêntica abaixo para cada um dos casos de teste.

ESPECIFICAÇÃO DE CASO DE TESTE	
Identificador:	PROJECT-TCS-CSW-0010
Objetivo:	Este teste deve verificar
Autor(es)	Autor(es) do caso de teste
Especificação de Entradas Efetuar login com username "Admin" pass "admin". b.	
Especificação de Saídas a. Todas as funcionalidades da aplicação ficam disponíveis. b. Administrador possui privilégios para poder consultar/modificar toda a informação existente.	
Outros NA	
Dependências Incluir as dependências deste caso de teste com outros	

- Espera-se que existam pelo menos 3 casos de teste para cada um dos requisitos funcionais. Esta informação, caso seja muito extensa, deve ser apresentada em Apêndice.

» **Cronograma**

- Apresentação do cronograma cumprido e comparação com o previsto. Incluir justificativa para possíveis desfasamentos.

» **Meios previstos e meios necessários**

- Descrição dos meios humanos e materiais utilizados e justificativa de desfasamentos perante os previstos.

» **Problemas e decisões**

- Problemas detetados e decisões tomadas justificando-as.

» **Análise de resultados**

- Análise detalhada dos resultados obtidos com a concretização deste projeto tendo por base os resultados esperados e mencionados na introdução. Sempre que possível os resultados devem estar concretizados em métricas concretas.

As tabelas devem ser numeradas com algarismos arábicos (1, 2, 3, ...). O título deve ser escrito no topo, alinhado à esquerda (Times New Roman, tamanho 11 pt ou Arial, tamanho 10 pt). O cabeçalho da tabela deve ser descritivo, embora breve.

Exemplo:

Tabela 1.

As várias gerações de evolução da tecnologia

Colaborativa	Administrativa
.....	


As figuras devem ser numeradas com algarismos arábicos (1, 2, 3, ...). A legenda deve ser colocada, antes da imagem, alinhado à esquerda (Times New Roman, tamanho 11 pt ou Arial, tamanho 10 pt).

De acordo com a Figura 1

Exemplo:

Figura 1.

Legenda da figura



Conclusões

- É elaborada na conclusão dos estudos, representa a síntese do trabalho, sendo clara e breve (máximo 1/10 das páginas do corpo do trabalho).
- Incluir um balanço dos objetivos (referindo os que foram alcançados e os que ficaram por cumprir), bem como das dúvidas, indicações e constrangimentos surgidos ao longo da sua elaboração.
- Incluir limitações, contributos e possíveis evoluções futuras do trabalho efetuado.

- Finalizar com uma reflexão crítica sobre o estágio incluindo as aprendizagens e as dificuldades.
- Não se usam citações e nem referências bibliográficas.

Referências bibliográficas

- São ordenadas por ordem alfabética e respeitam um formato apresentação, como por exemplo as normas APA.
- Não devem referir-se dicionários a não ser que sejam especializados.
- Não devem mencionar-se obras que não foram referenciadas ao longo do corpo do texto a não ser que a sua menção seja de particular importância. Neste caso faz-se a distinção entre bibliografia consultada e bibliografia citada.

Glossário

- Relação em ordem alfabética de palavras ou expressões técnicas de uso restrito, acompanhadas das respetivas definições.

Apêndices/anexos

- O apêndice funciona como um texto de prolongamento da obra e é da autoria do autor da obra.
- O anexo é a compilação de dados, gráficos, ilustrações e outros elementos que não são da responsabilidade do autor da obra.

6.2. Limitações no Processamento de Dados Tabulares e Híbridos

Durante a fase de testes do sistema de *Retrieval-Augmented Generation* (RAG), identificou-se uma limitação arquitetónica no que concerne à extração de informação financeira e estruturada, como é o caso das tabelas de preçários e propinas. A raiz deste comportamento não reside no modelo generativo (OpenAI), mas sim no processo de ingestão e *parsing* documental do Azure AI Search.

Os documentos em formato PDF não armazenam informação de forma estruturada, baseando-se em coordenadas visuais estáticas. Ao utilizar o indexador padrão (*default parsing mode*), o sistema lineariza o texto, destruindo a coesão espacial das tabelas. Consequentemente, a associação lógica entre uma entidade (e.g., o nome de um curso) e o seu atributo (e.g., o valor da mensalidade) perde-se no vetor de texto, o que leva o modelo generativo a omitir a resposta para mitigar o risco de alucinação de dados. Adicionalmente, verificou-se uma discrepância semântica frequente entre a linguagem natural do utilizador (que questiona sobre "preços") e a terminologia institucional estrita presente nos documentos (como "propinas" ou "emolumentos"), o que reduz a eficácia da pesquisa estritamente baseada em palavras-chave.

6.3. Trabalho Futuro e Otimização da Arquitetura

Para colmatar as limitações descritas sem recorrer a sobrecargas ineficientes de *prompt engineering*, propõe-se, para iterações futuras do sistema, a reestruturação do *pipeline* de ingestão de dados. O objetivo passará pela substituição do extrator padrão pela integração do **Azure AI Document Intelligence** (utilizando o modelo de *Layout*). Esta ferramenta recorre a modelos de visão computacional avançada para identificar e reconstruir tabelas complexas, exportando-as em formatos estruturados como Markdown ou HTML antes da indexação, garantindo assim que o LLM receba o contexto financeiro com exatidão.

Adicionalmente, prevê-se a evolução do motor de busca para uma abordagem de **Pesquisa Híbrida (Hybrid Search)**, ativando a pesquisa vetorial semântica no Azure. Esta atualização tecnológica permitirá que a base de dados relacione conceitos sintaticamente distintos, mas semanticamente idênticos (e.g., mapeando a intenção de "preço" para os "emolumentos" do PDF), otimizando a recuperação de informação e tornando a API mais resiliente a variações na linguagem dos utilizadores.